

VAE回顾

VAE的目标是最大化对数似然函数

$$\sum_i \log p_{\theta}(\mathbf{x}^{(i)}) = \sum_i KL(q_{\phi}(\mathbf{z}|\mathbf{x}^{(i)})||p_{\theta}(\mathbf{z}|\mathbf{x}^{(i)})) + \sum_i \mathcal{L}(\theta, \phi; \mathbf{x}^{(i)})$$

其中,

$$\mathcal{L}(\theta, \phi; \mathbf{x}^{(i)}) = \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x})] = -KL(q_{\phi}(\mathbf{z}|\mathbf{x}^{(i)})||p_{\theta}(\mathbf{z})) + \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}^{(i)})} \log p_{\theta}(\mathbf{x}^{(i)}|\mathbf{z})$$

由于KL散度非负, 对数似然函数的变分下界即为上式中的 \mathcal{L} 项。一般来说, $p_{\theta}(\mathbf{z}|\mathbf{x}^{(i)})$ 是未知的, 或者难以获得显式表达式的, 因此, 直接优化对数似然函数是不可行的, 一般转而优化它的变分下界, 即上式中的 \mathcal{L} 项。Diederik P.Kingma和Max Welling提出了两个算法SGVB和AEVB去估计 \mathcal{L} 。

CVAE

VAE用的训练集是数据 $\{\mathbf{x}^{(i)}\}_{i=1}^N$ 。当生成数据时, 由隐变量 \mathbf{z} 控制生成数据 \mathbf{x} , 如果我们现在有的数据不只是 \mathbf{x} , 我们还有关于数据 \mathbf{x} 的一些额外信息 \mathbf{y} , 最简单的, 以手写数字为例, 它的标签0-9, 那么我们是否能够利用上这些额外的信息呢?

CVAE-1

一个简答的想法, 考虑条件概率分布 $p_{\theta}(\mathbf{x}|\mathbf{y})$, 套用原来的VAE模型, 我们不难作出以下推导:

$$\begin{aligned} KL(q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})||p_{\theta}(\mathbf{z}|\mathbf{x}, \mathbf{y})) &= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})} \log \frac{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})}{p_{\theta}(\mathbf{z}|\mathbf{x}, \mathbf{y})} \\ &= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})} \log \frac{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})p_{\theta}(\mathbf{x}|\mathbf{y})}{p_{\theta}(\mathbf{z}|\mathbf{x}, \mathbf{y})p_{\theta}(\mathbf{x}|\mathbf{y})} \\ &= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})} \log \frac{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})p_{\theta}(\mathbf{x}|\mathbf{y})}{p_{\theta}(\mathbf{x}, \mathbf{z}|\mathbf{y})} \\ &= KL(q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})||p_{\theta}(\mathbf{x}, \mathbf{z}|\mathbf{y})) + \log p_{\theta}(\mathbf{x}|\mathbf{y}) \end{aligned}$$

于是

$$\log p_{\theta}(\mathbf{x}|\mathbf{y}) = KL(q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})||p_{\theta}(\mathbf{x}, \mathbf{z}|\mathbf{y})) + \mathcal{L}(\theta, \phi; \mathbf{x}, \mathbf{y})$$

其中,

$$\begin{aligned} \mathcal{L}(\theta, \phi; \mathbf{x}, \mathbf{y}) &= -KL(q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})||p_{\theta}(\mathbf{x}, \mathbf{z}|\mathbf{y})) \\ &= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})} [\log p_{\theta}(\mathbf{x}, \mathbf{z}|\mathbf{y}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})] \\ &= -KL(q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})||p_{\theta}(\mathbf{z}|\mathbf{y})) + \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})} \log p_{\theta}(\mathbf{x}|\mathbf{y}, \mathbf{z}) \end{aligned}$$

类似于VAE, 套用SGVB算法, 再做一下reparameterization, 取适当的分布和网络, 我们就得到了一个CVAE模型。

我们姑且称这个版本的CVAE为CVAE-1模型, 没错, CVAE模型不止一个.....

CVAE-2

此外，与CGAN一样，我们一般假设额外信息 \mathbf{y} 与隐变量 \mathbf{z} 没有直接的关系，因此条件概率 $p_{\theta}(\mathbf{z}|\mathbf{y}) = p_{\theta}(\mathbf{z})$ ，于是变分下界可以写成

$$\mathcal{L}(\theta, \phi; \mathbf{x}, \mathbf{y}) = -KL(q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})||p_{\theta}(\mathbf{z})) + \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})} \log p_{\theta}(\mathbf{x}|\mathbf{y}, \mathbf{z})$$

这在文献[3]中提到过。姑且称这个版本为CVAE-2模型。

CVAE-3

这就完了吗？文献[2]会告诉你，不要着急，我们也提出了一种CVAE。文中提出的方法不是产生数据 \mathbf{x} ，而是直接考虑预测问题：预测数据 \mathbf{x} 的标签 \mathbf{y} 。什么意思呢？它的似然函数是 $p_{\theta}(\mathbf{y}|\mathbf{x})$ 而不是 $p_{\theta}(\mathbf{x}|\mathbf{y})$ 。而这个推导也不难，事实上，把 \mathbf{y} 看成我们要生成的“数据”， \mathbf{x} 看成是“标签”，在上面推导的结果里面直接交换 \mathbf{x}, \mathbf{y} 的位置，就得到了

$$\log p_{\theta}(\mathbf{y}|\mathbf{x}) = KL(q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})||p_{\theta}(\mathbf{z}|\mathbf{x}, \mathbf{y})) + \mathcal{L}(\theta, \phi; \mathbf{x}, \mathbf{y})$$

其中，

$$\begin{aligned} \mathcal{L}(\theta, \phi; \mathbf{x}, \mathbf{y}) &= -KL(q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})||p_{\theta}(\mathbf{y}, \mathbf{z}|\mathbf{x})) \\ &= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})} [\log p_{\theta}(\mathbf{y}, \mathbf{z}|\mathbf{x}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})] \\ &= -KL(q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})||p_{\theta}(\mathbf{z}|\mathbf{x})) + \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})} \log p_{\theta}(\mathbf{y}|\mathbf{x}, \mathbf{z}) \end{aligned}$$


同样地，对 $q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})$ 做一下reparameterization，写成 $\mathbf{z} = g_{\phi}(\mathbf{x}, \mathbf{y}, \epsilon), \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。再取适当的分布和网络，就可以了。值得一提的是，我们会在模型中设定适当的分布 $p_{\theta}(\mathbf{y}|\mathbf{x}, \mathbf{z})$ ，当训练完了以后，可以把模型当成一个分类器，预测输入 \mathbf{x} 的标签：

$$\mathbf{y}^* = \arg \max_{\mathbf{y}} p_{\theta}(\mathbf{y}|\mathbf{x}, \mathbf{z}^*), \quad \mathbf{z}^* = \mathbb{E}[\mathbf{z}|\mathbf{x}]$$

上面的预测涉及到求期望，除非有显式结果，否则一般采用均值去近似期望：

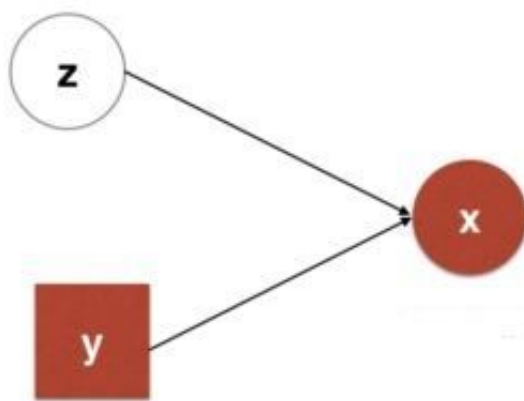
$$\mathbf{y}^* = \arg \max_{\mathbf{y}} \frac{1}{L} \sum_{l=1}^L p_{\theta}(\mathbf{y}|\mathbf{x}, \mathbf{z}^{(l)}), \quad \mathbf{z}^{(l)} \sim p_{\theta}(\mathbf{z}|\mathbf{x})$$

姑且这个模型称为CVAE-3，它的图模型结构如下：




CVAE-4

非常抱歉地告诉你，CVAE模型还没完。文献[3]提出了CMMA模型（conditional multimodal autoencoder），实际上它也可以看成是条件版本的VAE。一般来说，我们考虑的CVAE或者CGAN的图模型是长这样的：



它的特点是 \mathbf{z} , \mathbf{y} 一般是相互独立的。而CMMA考虑的图模型是长这样的：



这个模型的特点是隐变量是由额外信息 \mathbf{y} 确定的， $p_{\theta}(\mathbf{x}|\mathbf{y}, \mathbf{z}) = p_{\theta}(\mathbf{x}|\mathbf{z})$ 。整个推导过程跟CVAE-1一模一样，应用 $p_{\theta}(\mathbf{x}|\mathbf{y}, \mathbf{z}) = p_{\theta}(\mathbf{x}|\mathbf{z})$ 以后，变分下界可以简化为：

$$\mathcal{L}(\theta, \phi; \mathbf{x}, \mathbf{y}) = -KL(q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y}) || p_{\theta}(\mathbf{z}|\mathbf{y})) + \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}, \mathbf{y})} \log p_{\theta}(\mathbf{x}|\mathbf{z})$$

姑且称CMMA模型为CVAE-4。CVAE-4模型将标签信息编码到隐变量 \mathbf{z} 中，作者指出，这样做的效果更好。

当然，针对具体的问题，还有一些不一样的CVAE设计，例如，文献[1]用CVAE做半监督学习，用到的CVAE又与上面介绍的有所不同。根据具体问题，有些模型还会对目标函数添加一些惩罚项。

VAE是个贝叶斯模型，它的条件概率版本根据取条件概率的形式不同，自然会出现多种多样的模型。

代码

- \1. [RuiShu/cvae: Conditional variational autoencoder implementation in Torch](#)
- \2. [kastnerkyle/SciPy2015: Talk for SciPy2015 "Deep Learning: Tips From The Road"](#)
- \3. [Tutorial on Variational Autoencoders](#)
- \4. [dpkingma/nips14-ssl: Code for reproducing results of NIPS 2014 paper "Semi-Supervised Learning with Deep Generative Models"](#)
- \5. [jramapuram/CVAE: Convolutional Variational Autoencoder](#)

参考文献

- \1. Kingma D P, Mohamed S, Rezende D J, et al. Semi-supervised learning with deep generative models[C]//Advances in Neural Information Processing Systems. 2014: 3581-3589.
- \2. Sohn K, Lee H, Yan X. Learning structured output representation using deep conditional generative models[C]//Advances in Neural Information Processing Systems. 2015: 3483-3491.
- \3. Pandey G, Dukkipati A. Variational methods for conditional multimodal learning: Generating human faces from attributes. arXiv preprint[J]. arXiv, 2016, 1603.
- \4. Walker J, Doersch C, Gupta A, et al. An uncertain future: Forecasting from static images using variational autoencoders[C]//European Conference on Computer Vision. Springer International Publishing, 2016: 835-851.
- \5. Doersch C. Tutorial on variational autoencoders[J]. arXiv preprint arXiv:1606.05908, 2016.